강한 탐지기 위에서 LoRA 적응 VLM은 결함을 더 잘 진단하는가

MVTec LOCO AD 이상 탐지 + Qwen3-VL QLoRA 2줄 이상 리포트 · Hyung Jun LIM · 2026-10-30 · RTX 3060 12GB 1장

- SALAD 탐지기(공식 가중치 재현, image AUROC 96.1)가 이상을 거르고, QLoRA로 적응시킨 Qwen3-VL-4B가 결함 그룹·세부·위치·조치를 고정 템플릿 2줄로 출력한다. 정상이면 무출력.
- LoRA 적응: 같은 4B의 zero-shot 대비 결함 그룹 정확도 6.0% → 55.7% (seed 3개 평균), 형식 준수 14.0% → 99.9%.
- 캐스케이드는 VLM 단독(B2)보다 종단 정답 그룹 F1이 +10.5%p [+7.2, +13.9] 높다(사전 성공 기준 충족).
- **음성 결과**: 같은 탐지기 특징을 쓰는 비-VLM 분류기(B1)가 그룹 정확도 67.0%로 10.8%p 앞서고, 같은 캐스케이드의 종단 F1도 68.7 vs 55.6. 사전 등록 원칙대로 그대로 보고하고 원인을 분해했다.

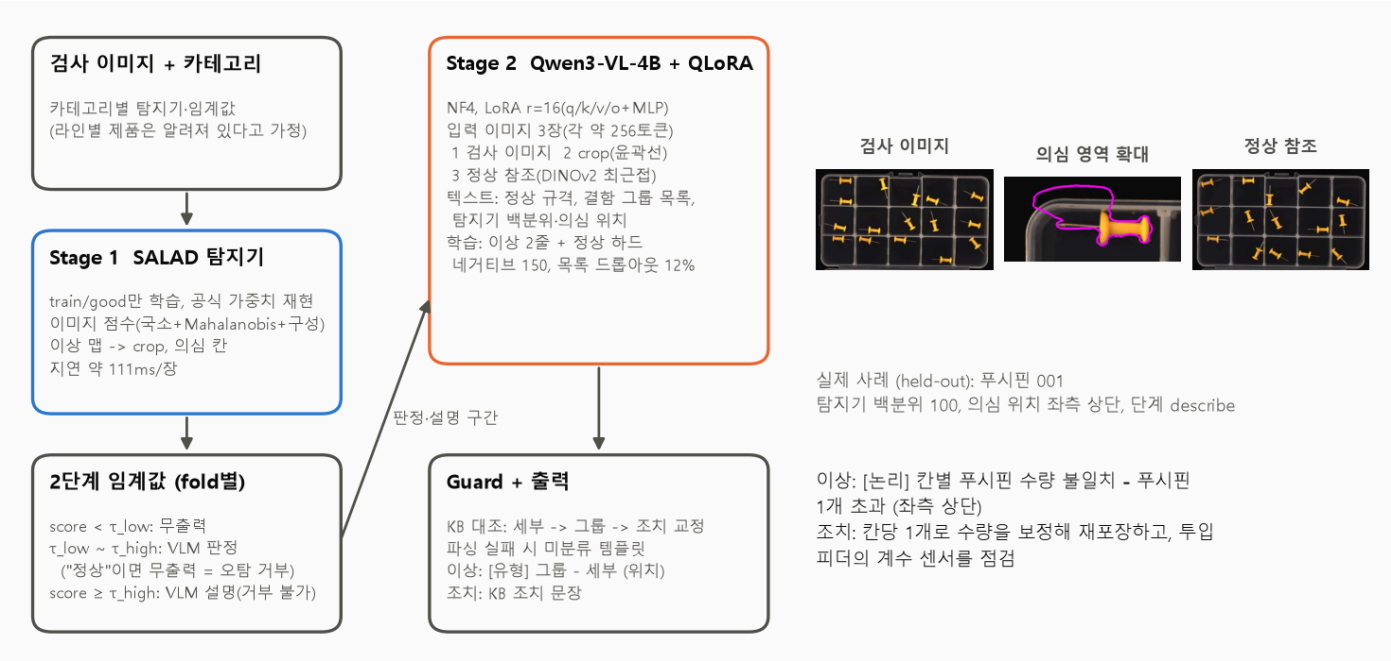


그림 1. 시스템 구조(왼쪽)와 held-out 실제 사례(오른쪽: VLM 입력 이미지 3장과 최종 2줄 출력). τ_low는 학습 측 이상 재현율 0.95, τ_high는 학습 측 정상 FPR 1% 지점이며 fold별로 학습 측 test 이미지로만 정한다.

1. 문제 설정

VLM으로 LOCO의 논리 이상을 직접 탐지한 선행연구(LogicAD 86.0, LogicQA 87.6 AUROC)는 전용 탐지기(SALAD 96.1)에 못 미친다. 그래서 VLM을 탐지기가 아니라 **탐지 뒤의 진단기**로 두고, 이상 의심 이미지에만 결함 그룹(36개), 세부 결함(89종), 위치(3x3 칸), 조치(가상 SOP)를 2줄로 내게 했다. 핵심 질문은 "강한 탐지기가 있을 때 VLM이 비-VLM 진단기보다 나은가"이며, 결과 전에 네 가지 연구 질문과 가설·판정 기준을 계획 문서에 등록했다.

- **RQ1 진단 이득**: LoRA VLM이 비-VLM 진단기(B1)보다 결함 진단을 개선하는가.
- **RQ2 입력 단서**: 정상 참조, 이상 영역 crop, 규격 텍스트는 각각 어떤 결함 유형에 기여하는가.
- **RQ3 미등록 결함**: 학습 중 결함 목록 일부를 지우는 "목록 드롭아웃"이 처음 보는 결함에 "미분류"로 답하게 하는가.
- **RQ4 거부 단계**: VLM의 오탐 거부가 재현율 손실(1%p 이하)보다 큰 오경보 감소(절반 이상)를 내는가.

2. 방법과 평가 설계

데이터와 누수 방지

- test 1,568장(정상 575, 이상 993)을 (카테고리, 라벨, 결함 그룹) 층화 2-fold로 나누고, 각 이미지는 자기를 학습하지 않은 fold 모델의 예측으로만 채점한다. 근접 중복은 같은 fold로 모았다.
- 설정 선택은 학습 측 15% inner-val로만, epoch는 3으로 미리 고정. 임계값은 학습 측 test 이미지로만 정한다 (validation/good은 SALAD 정규화에 쓰여 점수가 in-sample이라 제외).
- 위치 라벨: GT 마스크 통계로 세부 결함마다 위치 방식을 정했다. 수량 초과 계열은 같은 종류 부품을 모두 칠한 GT라 초과분 위치를 정의할 수 없어 위치를 생략한다.

탐지기와 캐스케이드

- SALAD 공식 test 경로를 감싸 이미지별 점수 3항과 맵을 저장하는 래퍼를 구현하고, 저장값으로 다시 계산한 AUROC 4종이 공식 출력과 같음(차이 0)을 확인했다. 배포 가중치 1개의 손상(zip 안에 다른 파일 24개가 덧붙음)도 찾아 복구했다.

VLM 적응

- Qwen3-VL-4B-Instruct, NF4 QLoRA(r=16, q/k/v/o + MLP, 비전 인코더 비양자화). 입력은 검사 이미지, 탐지기 crop(윤곽선), DINOv2 최근접 정상 참조(각 약 256토큰)와 규격·결함 그룹 목록·탐지기 백분위 텍스트.
- SFT: 이상 2줄 정답 + 탐지 점수 상위 정상 하드 네거티브 150장 + 목록 드롭아웃 12%(정답을 "미분류 이상 - 서술"로). 손실은 정답 토큰 위치의 logits만 계산해 12GB 안에서 학습(최대 6.32GB, fold당 2.08시간).
- Guard: 출력을 KB와 대조해 세부 → 그룹 → 조치 순으로 교정. 지표는 Guard 전 원출력 기준.

기준선과 통계

- B0 최빈값, B1 비-VLM(DINOv2 전역·crop 특징 + SALAD 점수 3항 → 로지스틱 회귀), B2 VLM 단독(탐지기·crop 없음, 같은 QLoRA), B3 무학습 프롬프트(zero/few-shot). 모두 같은 2줄 형식과 같은 채점기로 평가.
- 주요 비교는 같은 이미지의 쌍대 비교(paired bootstrap 95% CI + McNemar), ablation은 Holm 보정.

3. 결과

시스템	그룹	유형	세부	위치 적중	정상 거부	형식	종단 그룹 F1 test / π=1%	생성(초/장)	VRAM(GB)
B0 최빈값	28.7	56.5	10.0	24.3	0.0	100.0	25.4 / 2.2	-	-
B1 비-VLM 진단기	67.0	76.0	61.9	70.8	86.6	100.0	68.7 / 19.7	-	-
B2 VLM 단독(4B)	44.0	56.1	33.2	44.0	66.4	99.8	45.5 / 2.5	5.8	5.92
B3 zero-shot(4B)	6.0	5.3	0.2	0.3	0.2	14.0	5.6 / 0.5	-	-
B3 few-shot(4B)	29.2	48.6	2.7	49.8	6.8	95.5	27.2 / 2.4	-	-
Ours 2B LoRA	43.7	64.8	27.7	66.0	82.1	100.0	44.0 / 9.3	2.4	7.4
Ours 4B QLoRA	**55.7**	**71.4**	**44.5**	**69.0**	**86.8**	**99.9**	**55.6 / 10.6**	**6.1**	**6.32**
P2: 8B QLoRA	56.4	70.3	43.2	70.7	90.6	99.9	57.7 / 14.3	22.4	11.57

표 1. 두 held-out fold 합산(이상 993, 정상 575), 원출력. 설명 지표는 정답 이상을 모두 넣은 oracle 게이팅. 종단 그룹 F1은 각 시스템의 예측을 같은 SALAD 캐스케이드에 넣은 최종 출력 기준(B2만 탐지기 없음), π 보정 정밀도 = π·R / (π·TPR + (1-π)·FPR). Ours 4B는 seed 3개 평균(그룹 55.4~56.2). 탐지기 지연 약 111ms/장.

RQ1. 비-VLM 진단기가 더 강하다 (가설 기각)

LoRA 적응 자체는 효과가 컸다(zero-shot 대비 그룹 +50.2%p, $p<0.001$; 학습 전후 MMAD 객관식 정확도 56.5 → 56.6, 56.4 → 56.1로 망각 없음). 그러나 같은 탐지기 특징을 쓰는 B1이 그룹 정확도에서 10.8%p [7.3, 14.2] 앞섰고($p<0.001$), 가설이 VLM의 강점으로 본 논리 결함에서도 B1이 높았다(75.8 vs 63.3). 2B LoRA(43.7)는 4B보다 12.5%p 낮지만 생성은 2.4초/장으로 빠르다.

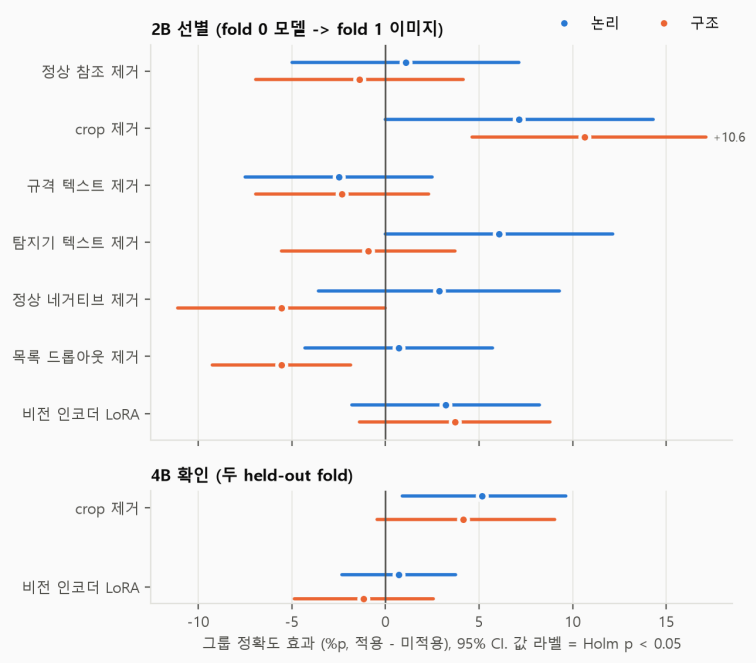


그림 3. 입력·학습 요소별 효과(적용 - 미적용, 그룹 정확도, 95% CI). 위: 2B fold 0 모델 → fold 1 이미지 선별. 아래: 효과 상위 2개의 4B 2-fold 확인. 값 라벨은 Holm p < 0.05.

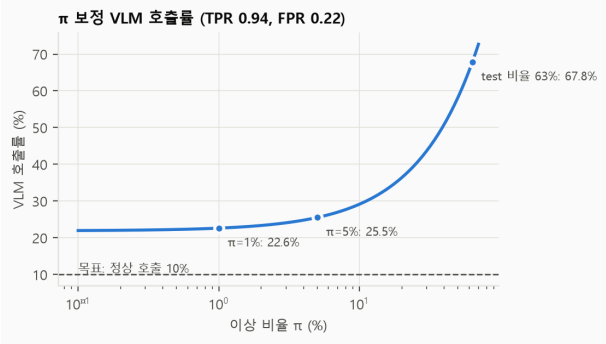


그림 2. 이상 비율 π에 따른 VLM 호출률(탐지기 단계 통과율) = π·TPR + (1-π)·FPR. test의 이상 비율(63%)은 실제 라인보다 훨씬 높다.

RQ2. crop만 유의하게 기여한다

이상 영역 crop을 빼면 그룹 정확도가 8.7%p 떨어졌고(구조 결함 10.6%p, Holm p=0.025), 정상 거부도 31.0%p 낮아졌다. 정상 참조(+0.0%p)와 규격 텍스트(-2.4%p)는 효과가 없어 "논리 결함에 기여한다"는 가설을 지지하지 못했다. 탐지기 텍스트는 그룹보다 위치에 기여했다(위치 적중 63.0 → 45.4). 비전 인코더 LoRA는 +3.4%p(p=0.075)였고 "작은 부품 개수 세기에 필요하다"는 가설과 달리 개수 계열 효과는 +1.2%p였다. 효과 상위 2개를 4B 두 fold에서 다시 확인하자 crop 효과는 재현됐고(+4.7%p [+1.5, +8.0], p=0.0049, 논리 +5.2·구조 +4.2로 고르게 분산), 비전 인코더 LoRA는 재현되지 않았다(-0.1%p, 정상 거부 -4.9%p, p<0.001). 그래서 주력 설정은 비전 인코더를 동결한 채로 둔다.

RQ3. 목록 드롭아웃의 효과는 작다

구조형(이물 혼입 제외): 처음 보는 결함에 "미분류"로 답한 비율이 드롭아웃 있음 7.9% vs 없음 0.0%(p=0.062), 기존 그룹으로 잘못 분류한 비율 81.0% vs 88.9%. 논리형(카테고리별 1그룹 제외): 처음 보는 결함에 "미분류"로 답한 비율이 드롭아웃 있음 4.1% vs 없음 0.0%(p=0.25), 기존 그룹으로 잘못 분류한 비율 90.5% vs 95.9%. 두 실험 모두 방향은 가설과 같지만 유의하지 않았고 대부분 기존 그룹으로 흡수됐다. 드롭아웃 정답의 서술이 알려진 결함의 KB 문구라 모델이 새 결함도 기존 어휘로 서술하는 한계가 있다(사전 정한 핵심어 일치는 지표를 사후에 바꾸지 않고 그대로 보고). 탐색 관찰(사전 등록 아님)로, 논리형에서는 드롭아웃 모델의 알려진 결함 정확도가 53.3 vs 58.3로 낮아(p=0.0025) 미분류 응답과 정확도 사이의 trade-off 가능성이 보였다.

RQ4. 오경보는 크게 줄지만 재현율도 잃는다

학습 측 재현율 0.95 기준에서 탐지기 단독은 재현율 94.5 / FPR 21.9, 캐스케이드는 90.4 / 7.7로 오경보를 65% 줄였지만 재현율을 4.0%p 잃어 가설(1%p 이하)을 충족하지 못했다. π=1%의 VLM 호출률은 22.6%로 목표 10%를 넘는데, 원인은 탐지기 FPR이다. VLM 단독(B2) 대비 종단 정답 그룹 F1은 seed 3개 모두 높았다(+10.5, +9.7, +10.0%p). **후속(사전 등록)**: 판정 구간 거부를 B1의 정상 판정에 맡기면 오경보 감소 78%, 호출률 5.7%로 목표를 넘지만 재현율 손실이 5.3%p로 커져 여전히 미충족이다(seed 3개, 종단 그룹 F1 -0.7%p [-1.5, +0.0]).

이상 993장	장수	비율	정상 575장	장수	비율
탐지기 놓침(통과 구간)	55	5.5	통과(무출력)	449	78.1
VLM 오거부(판정 구간)	40	4.0	VLM 거부(판정 구간)	82	14.3
그룹 오답(판정 구간)	45	4.5	오경보: 판정 구간 VLM 이상 판단	36	6.3
그룹 오답(설명 구간)	311	31.3	오경보: 설명 구간(거부 불가)	8	1.4
정답	542	54.6			

표 2. 오류 분해(Ours 4B seed 0, 최종 출력). 종단 오류 451장 중 VLM 그룹 오답이 79%, 탐지기 놓침이 12%. 탐지기가 놓친 이상 중 VLM 원출력이 맞았던 것은 16장뿐이라 병목은 탐지가 아니라 VLM의 진단이다.



그림 4. held-out 성공 3건과 실패 3건. 사례는 결과를 보고 고르지 않도록 규칙으로 정했다(세 seed에서 정오가 같은 이미지, 카테고리 중복 없이 id 순, 실패는 유형 3종).

4. 왜 VLM이 B1에 지는가

결함 종류로 나누면 **개수 계열**(과일·푸시핀·부품 수량, 169장)은 Ours 64.3 vs B1 64.5로 같고, 격차는 **그 밖의 논리 결함**(60.3 vs 80.6)과 구조 결함(48.1 vs 55.6)에서 나온다. 가장 큰 격차는 칸막이 누락(2.6 vs 100.0, 대부분 푸시핀 수량으로 혼동)과 케이블 길이(47.2 vs 100.0) 같은 장면 전체의 구성 결함으로, B1이 쓰는 SALAD 구성 점수에 직접 드러나는 결함이다. 나사 길이와 부품 수량의 상호 혼동(36+18장)도 컸다. crop이 결함을 다 담지 못하면 정확도가 떨어졌고(개수 계열 crop 포함률 100% 72.1 vs 50% 미만 51.7), 참조 유사도와의 관계는 카테고리 안에서 다시 보면 사라졌다(카테고리 교란).

추가 실험 P2: 모델 용량을 늘려도, 라벨을 늘려도 격차는 그대로였다

격차의 원인 후보 둘을 결과 전에 가설로 등록하고 확인했다. **모델 크기.** 8B QLoRA는 4B seed 0 대비 +0.2%p [-2.9, +3.2](p=0.95)로 차이가 없었고 B1에는 -10.6%p 뒤졌다. 비용은 fold당 학습 8.1h(4B 1.4h), 예약 VRAM 11.6GB로 12GB 한계에 닿았다. **라벨 수.** 학습 라벨 25 → 50 → 100%에서 2B VLM은 23.0 → 33.7 → 43.3, B1은 46.6 → 56.9 → 65.5로, 라벨 2배당 증가폭 (VLM +10.2 vs B1 +9.5%p)이 비슷해 두 곡선은 평행하고 격차(22.2%p)는 그대로다. VLM은 라벨 25%(이상 107장)에서 정상 거부 0.0%로 사실상 학습되지 않았다.

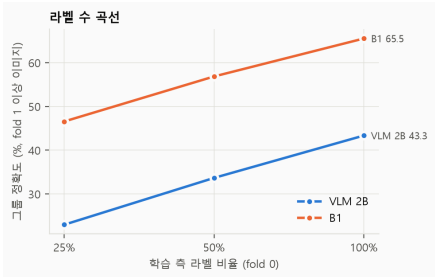


그림 5. 라벨 수 곡선(fold 0 학습 측 라벨 비율 → fold 1 이상 이미지, 그룹 정확도).

추가 실험 P3: 구성 점수를 글로 주어도 부족했고, B1의 판정을 주면 VLM은 대체로 받아 적었다

남은 원인 후보인 입력 표현을 2B 선별 → 4B 확인 틀로 검증했다. **구성 신호.** SALAD 세 항의 백분위를 프롬프트에 넣어도 기타 논리 결함은 +0.5%p(Holm p=1, 가설 미지지), 그룹 전체 +3.0%p [-0.4, +6.5]였다. **B1 후보 힌트.** B1 상위 2그룹의 확률을 넣으면 2B의 격차 22.2%p는 사라졌지만(65.7 vs B1 65.5) 출력의 87.1%가 힌트 1위와 같고 틀린 힌트의 교정은 9.2%였다. 4B 확인에서도 +13.9%p [+10.9, +17.0]로 재현됐고 B1을 +3.1%p [+0.8, +5.4] 넘었다(탐색적). 4B는 복사율 77.1%, 틀린 힌트 교정 24.7%, 틀린 힌트 복사 46.8%다. 즉 점수 한 줄로는 격차가 메워지지 않았고, 힌트의 이득은 VLM 단독 진단의 개선이 아니라 판정은 B1, 검증·설명은 VLM인 계층 구성의 결과다.

5. 직무 연결과 한계

- **PEFT 도메인 적응**: 12GB GPU에서 2B LoRA, 4B·8B QLoRA(정답 토큰 logits만 계산), 비전 인코더 LoRA를 비교하고 정확도·VRAM·지연을 함께 보고했다. 적응 전후 망각(MMAD)도 측정했다.
- **논문 구현**: SALAD 점수 추출을 재구현해 공식 수치와 일치를 검증하고 배포 가중치 결함을 찾아 고쳤다.
- **연구 주도**: 가설·판정 기준을 결과 전에 등록하고, 가설과 반대인 결과(B1 우세)를 숨기지 않고 원인을 분해했다. 학습은 감독자·체크포인트 재개·자동 원복 장치로 운영했다(대기열 134시간 동안 GPU 유휴 146분, 그중 135분은 대기열 설정 오류 1건. 고장 주입 시험 9종). 예측 원본·어댑터를 공개해 GPU 없이 표를 재계산할 수 있고 CI가 검사한다.
- **한계**: 소표본 그룹(36개 중 다수가 10장 미만), fold 2개, 공개 데이터의 사전학습 노출 가능성, 가상 SOP 조치, 위치는 point 결함만 채점. 의료 영상으로 옮길 때는 놓침 비용이 크므로 τ_low를 더 보수적으로 두고 단순 분류기 기준선을 먼저 확인해야 한다.

코드·재현 절차: 저장소 README. 데이터: MVTec LOCO AD(CC BY-NC-SA 4.0, Bergmann et al., IJCV 2022), 그림 속 이미지도 같은 조건. 모든 수치는 reports/tables의 결과 파일에서 빌드 시 채워 넣었다(빌드 2026-10-30 23:07).